



Instituto Infnet

TRABALHO FINAL DE CURSO

Análise de dados com Spark [24E3_3]

Aluno: Gustavo Quirino Gomes Turma: LDA-L | C0 | L1 | PGL LDA01C0-24-L1

Orientador : **Prof. Andre Victor**

1. Introdução

A previsão de preços de imóveis é um problema clássico de Ciência de Dados, pois envolve a análise de múltiplas variáveis que podem influenciar diretamente o valor de mercado de uma propriedade. Características como área construída, número de quartos, número de banheiros, localização, condição do imóvel e ano de construção podem ter impacto relevante no preço final de venda.

Neste trabalho, foi desenvolvido um modelo preditivo utilizando **Apache Spark**, com o objetivo de estimar o preço de venda de imóveis a partir de atributos disponíveis em uma base pública de dados. O uso do Spark se justifica pela sua capacidade de processar grandes volumes de dados de forma distribuída, além de oferecer bibliotecas próprias para transformação de dados e aprendizado de máquina, como o **Spark MLlib**.

O algoritmo escolhido para a primeira modelagem foi a **Regressão Linear**, técnica supervisionada utilizada para prever valores numéricos contínuos. Como a variável de interesse do projeto é o preço de venda dos imóveis, trata-se de um problema típico de regressão.

2. Objetivo geral

Desenvolver um modelo preditivo utilizando Apache Spark para estimar o preço de venda de imóveis com base em características presentes no conjunto de dados.

3. Objetivos específicos

- Carregar e explorar o conjunto de dados de imóveis.
- Identificar a variável-alvo do modelo.
- Selecionar atributos relevantes para a previsão do preço.
- Realizar transformações e preparação dos dados.
- Aplicar um modelo de Regressão Linear com Spark MLlib.
- Avaliar o desempenho do modelo utilizando métricas como R^2 e MAE.
- Comparar os resultados antes e depois da remoção de outliers.
- Analisar as limitações do modelo utilizado.
- Propor melhorias para trabalhos futuros.

4. Base de dados

O conjunto de dados utilizado neste trabalho foi o **House Sales Prediction**, disponível na plataforma Kaggle(<https://www.kaggle.com/datasets/harlfoxem/housesalesprediction>). A base contém informações relacionadas a imóveis, incluindo dados como preço, tamanho, número de quartos, número de banheiros, localização e demais atributos imobiliários.

A variável mais importante do estudo é o **price**, que representa o preço de venda do imóvel. Essa variável foi utilizada como **variável-alvo** do modelo de aprendizado supervisionado.

As demais variáveis foram utilizadas como possíveis atributos explicativos, isto é, características que podem contribuir para estimar o preço do imóvel.

Exemplos de variáveis relevantes para esse tipo de problema incluem:

Variável	Descrição
price	Preço de venda do imóvel
bedrooms	Número de quartos
bathrooms	Número de banheiros
sqft_living	Área construída
sqft_lot	Área do terreno
floors	Número de andares
waterfront	Indicação de vista para água
condition	Condição do imóvel
grade	Classificação geral do imóvel
yr_built	Ano de construção
zipcode	Código/localização do imóvel

5. Metodologia

A metodologia adotada no projeto seguiu as principais etapas de um fluxo de Ciência de Dados: ingestão dos dados, exploração, transformação, treinamento do modelo, avaliação e análise dos resultados.

Inicialmente, a base de dados foi carregada em ambiente compatível com Apache Spark. Em seguida, foram realizadas etapas de análise exploratória para compreender a estrutura do conjunto de dados, os tipos das variáveis, a existência de valores ausentes, possíveis inconsistências e a distribuição da variável preço.

Após a análise inicial, foram realizadas transformações nos dados para adequá-los ao formato exigido pelo modelo de Machine Learning do Spark. Para isso, as variáveis explicativas foram organizadas em um vetor de características, etapa normalmente realizada com o componente **VectorAssembler** do Spark MLlib.

Conjunto	Proporção	Finalidade
Treinamento	80%	Ajustar o modelo
Teste	20%	Avaliar a capacidade preditiva

6. Modelo utilizado

O algoritmo escolhido foi a **Regressão Linear**, um dos modelos mais tradicionais para problemas de previsão de valores contínuos. Esse modelo busca encontrar uma relação linear entre as variáveis explicativas e a variável-alvo.

No contexto deste projeto, a regressão linear tenta estimar o preço do imóvel com base em características como número de quartos, banheiros, área, localização e demais atributos disponíveis.

Apesar de ser um modelo simples e interpretável, a Regressão Linear possui limitações importantes. Ela pressupõe que existe uma relação aproximadamente linear entre as variáveis explicativas e a variável-alvo. Em problemas imobiliários, essa suposição pode não ser totalmente verdadeira, pois o preço de um imóvel pode depender de interações complexas e não lineares entre localização, tamanho, padrão de construção, idade do imóvel e condições de mercado.

7. Métricas de avaliação

Para avaliar o desempenho do modelo, foram utilizadas duas métricas principais: **R^2** e **MAE**.

O **Coefficiente de Determinação**, conhecido como **R^2** , indica quanto da variação da variável-alvo é explicada pelo modelo. Um R^2 de 70,1% significa que o modelo conseguiu explicar aproximadamente 70,1% da variabilidade dos preços com base nas variáveis utilizadas.

O **Erro Médio Absoluto**, conhecido como **MAE**, indica o erro médio das previsões em relação aos valores reais. No primeiro modelo, o MAE foi de **US\$ 127.493**, o que significa que, em média, as previsões ficaram aproximadamente 127 mil dólares distantes do preço real dos imóveis.

8. Resultados obtidos

Na primeira modelagem, sem a remoção dos outliers, o modelo apresentou os seguintes resultados:

Cenário	R^2	MAE
Modelo inicial	70,1%	US\$ 127.493

Esse resultado indica que o modelo apresentou uma capacidade explicativa razoável, conseguindo representar parte significativa da variação dos preços. No entanto, o erro médio absoluto ainda foi elevado, especialmente considerando que preços de imóveis

podem variar bastante em função de localização, padrão de construção e características específicas.

Em uma segunda etapa, foi realizada a remoção de outliers. Após esse tratamento, os resultados foram:

Cenário	R ²	MAE
Após remoção de outliers	68,7%	US\$ 86.165

A remoção de outliers reduziu significativamente o MAE, indicando que o modelo passou a cometer erros médios menores. Entretanto, houve uma pequena redução no R², de 70,1% para 68,7%.

Esse comportamento pode ocorrer porque a remoção de valores extremos reduz a dispersão geral dos dados e pode alterar a variabilidade explicada pelo modelo. Em outras palavras, o modelo passou a errar menos em média, mas sua capacidade de explicar toda a variação dos preços foi levemente reduzida.

9. Análise dos resultados

Os resultados indicam que a Regressão Linear apresentou desempenho razoável como modelo inicial. O R² próximo de 70% demonstra que o modelo conseguiu capturar parte relevante da relação entre as características dos imóveis e seus preços.

No entanto, o MAE inicial de US\$ 127.493 indica que o erro médio ainda era elevado. Após a remoção dos outliers, houve uma melhora expressiva no MAE, que caiu para US\$ 86.165. Isso sugere que valores extremos estavam impactando negativamente o desempenho do modelo.

Por outro lado, a redução do R² após a remoção dos outliers mostra que a melhoria do MAE não necessariamente representa uma melhoria global em todas as dimensões do modelo. Essa diferença reforça a importância de avaliar modelos com mais de uma métrica.

Além disso, a análise de correlação por meio de heatmap indicou que algumas variáveis apresentaram baixa correlação linear com a variável preço. Esse resultado sugere que o comportamento dos preços pode não ser completamente explicado por relações lineares simples.

Dessa forma, a Regressão Linear pode ser considerada um bom modelo de referência inicial, mas não necessariamente o melhor modelo para esse conjunto de dados.

10. Limitações do modelo

A principal limitação do modelo está relacionada à própria natureza da Regressão Linear. Esse algoritmo assume uma relação linear entre as variáveis independentes e a variável dependente. No mercado imobiliário, entretanto, os preços podem ser influenciados por relações complexas e não lineares.

Outra limitação é que a análise baseada apenas em correlação linear pode não capturar interações entre variáveis. Por exemplo, a localização pode ter impacto diferente dependendo da área do imóvel, do padrão de construção e da condição geral da propriedade.

11. Trabalhos futuros

Como melhoria para trabalhos futuros, recomenda-se comparar a Regressão Linear com modelos mais robustos e capazes de capturar relações não lineares, como:

Modelo	Justificativa
Decision Tree Regressor	Captura relações não lineares simples
Random Forest Regressor	Reduz overfitting e melhora generalização
Gradient Boosted Trees	Pode gerar alta performance em dados tabulares
Generalized Linear Regression	Alternativa estatística mais flexível
Cross Validation	Melhora a avaliação do modelo
Grid Search	Permite testar diferentes hiperparâmetros

12. Conclusão

Este trabalho demonstrou a aplicação de Apache Spark e técnicas de Machine Learning para a previsão de preços de imóveis. A utilização da Regressão Linear permitiu criar um modelo inicial capaz de explicar aproximadamente 70,1% da variabilidade dos preços na primeira modelagem.

O erro médio absoluto inicial foi de US\$ 127.493, indicando que, embora o modelo tenha apresentado capacidade explicativa razoável, ainda havia margem significativa para melhoria. Após a remoção dos outliers, o MAE foi reduzido para US\$ 86.165, demonstrando que o tratamento de valores extremos contribuiu para diminuir o erro médio das previsões.

Entretanto, o R^2 apresentou leve redução, passando de 70,1% para 68,7%. Esse resultado mostra que a remoção de outliers melhorou a precisão média, mas reduziu ligeiramente a capacidade explicativa geral do modelo.

A análise de correlação indicou que algumas variáveis possuem baixa correlação linear com o preço, sugerindo que a Regressão Linear pode não capturar toda a complexidade do problema. Assim, conclui-se que o modelo utilizado é adequado como ponto de partida, mas recomenda-se a comparação com algoritmos mais robustos, como Random Forest e Gradient Boosted Trees.

Dessa forma, o projeto atingiu seu objetivo principal ao demonstrar o uso do Spark para análise preditiva, ao mesmo tempo em que evidenciou a importância da avaliação crítica dos modelos e da escolha adequada de algoritmos para problemas de regressão.

Segue link para o notebook :

https://colab.research.google.com/drive/1hwb-4-lzgGX_ViUHYATGIZmxAyU7eIP?usp=sharing

Segue link para base de dados (arquivo csv):

https://drive.google.com/file/d/1c-6vJHDVsYt6TVr8QZADTLN_KgoDM45E/view?usp=sharing